Taller de syscalls y señales

Sistemas Operativos

Departamento de Computación, FCEyN, Universidad de Buenos Aires, Buenos Aires, Argentina

28 de marzo de 2017

Primer cuatrimestre de 2017

Como usuarios: programas o utilidades de sistema.
 Por ejemplo: ls, time, mv, who, akw, etc.

- Como usuarios: programas o utilidades de sistema.
 Por ejemplo: ls, time, mv, who, akw, etc.
- Como programadores: llamadas al sistema o syscalls.
 Por ejemplo: time(), open(), write(), fork(), wait(), etc.

- Como usuarios: programas o utilidades de sistema.
 Por ejemplo: ls, time, mv, who, akw, etc.
- Como **programadores**: llamadas al sistema o *syscalls*.

 Por ejemplo: time(), open(), write(), fork(), wait(), etc.
- Ambos mecanismos suelen estar estandarizados.
- Linux sigue el estándar POSIX (Portable Operating System Interface [for UNIX]).

- Las syscalls proveen una interfaz a los servicios brindados por el sistema operativo: la API (Application Programming Interface) del SO.
- La mayoría de los programas hacen un uso intensivo de ellas.

- Las syscalls proveen una interfaz a los servicios brindados por el sistema operativo: la API (Application Programming Interface) del SO.
- La mayoría de los programas hacen un uso intensivo de ellas.
- Implementación: en general, se usa una interrupción para pasar a modo kernel, y los parámetros se pasan usando registros o una tabla en memoria. En Linux: interrupción 0x80 (en 32 bits); el número de syscall va por EAX (o RAX).

- Las syscalls proveen una interfaz a los servicios brindados por el sistema operativo: la API (Application Programming Interface) del SO.
- La mayoría de los programas hacen un uso intensivo de ellas.
- Implementación: en general, se usa una interrupción para pasar a modo kernel, y los parámetros se pasan usando registros o una tabla en memoria. En Linux: interrupción 0x80 (en 32 bits); el número de syscall va por EAX (o RAX).
- Normalmente se las utiliza a través de wrapper functions en C.

- Las syscalls proveen una interfaz a los servicios brindados por el sistema operativo: la API (Application Programming Interface) del SO.
- La mayoría de los programas hacen un uso intensivo de ellas.
- Implementación: en general, se usa una interrupción para pasar a modo kernel, y los parámetros se pasan usando registros o una tabla en memoria. En Linux: interrupción 0x80 (en 32 bits); el número de syscall va por EAX (o RAX).
- Normalmente se las utiliza a través de wrapper functions en C. ¿Por qué no directamente?

Un primer ejemplo

```
tinyhello.asm
```

```
section .data
hello: db 'Hola SO!', 10
hello_len: equ $-hello
section .text
global _start
start:
 mov eax, 4; syscall write
 mov ebx, 1; stdout
 mov ecx, hello; mensaje
 mov edx, hello_len
  int. 0x80
 mov eax, 1; syscall exit
 mov ebx, 0;
  int 0x80
```

Lo mismo, en 64 bits

tinyhello_64.asm

```
section .data
hello: db 'Hola SO!', 10
hello_len: equ $-hello
section .text
global _start
start:
 mov rax, 1; syscall write
 mov rdi, 1; stdout
 mov rsi, hello; mensaje
 mov rdx, hello_len
  syscall
 mov rax, 60; syscall exit
 mov rdi, 0;
  syscall
```

Usando wrapper functions en C

- Claramente, el código anterior no es portable.
- Además, realizar una syscall de esta forma requiere programar en lenguaje ensamblador.
- Las wrapper functions permiten interactuar con el sistema con mayor portabilidad y sencillez.

Usando wrapper functions en C

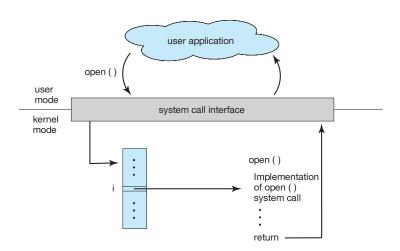
- Claramente, el código anterior no es portable.
- Además, realizar una syscall de esta forma requiere programar en lenguaje ensamblador.
- Las wrapper functions permiten interactuar con el sistema con mayor portabilidad y sencillez.

El ejemplo anterior, pero ahora en C:

```
hello.c
#include <unistd.h>

int main(int argc, char* argv[]) {
  write(1, "Hola SO!\n", 9);
  return 0;
}
```

Usando *wrapper functions* en C



Invocación de la syscall open() desde una aplicación de usuario.

Imagen extraída de Operating System Concepts (Abraham Silberschatz et al.)

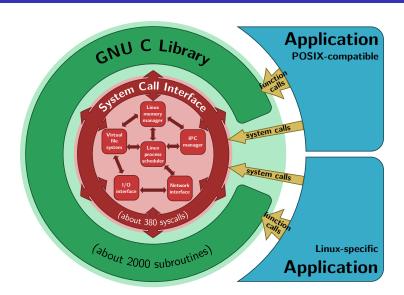
• Linux implementa todas las *syscalls* especificadas por el estándar POSIX, y también algunas adicionales.

- Linux implementa todas las syscalls especificadas por el estándar POSIX, y también algunas adicionales.
- Están definidas en el archivo unistd.h de la biblioteca estándar de
 C. Puede verse una lista de todas ellas usando man syscalls.

- Linux implementa todas las syscalls especificadas por el estándar POSIX, y también algunas adicionales.
- Están definidas en el archivo unistd.h de la biblioteca estándar de
 C. Puede verse una lista de todas ellas usando man syscalls.
- Pueden ver las syscalls con man syscalls

- Linux implementa todas las syscalls especificadas por el estándar POSIX, y también algunas adicionales.
- Están definidas en el archivo unistd.h de la biblioteca estándar de C. Puede verse una lista de todas ellas usando man syscalls.
- Pueden ver las syscalls con man syscalls
- Cada syscall, y sus correspondiente wrapper function en C, están descriptas en la sección 2 del manual (man 2 <syscall>).

- Linux implementa todas las syscalls especificadas por el estándar POSIX, y también algunas adicionales.
- Están definidas en el archivo unistd.h de la biblioteca estándar de C. Puede verse una lista de todas ellas usando man syscalls.
- Pueden ver las syscalls con man syscalls
- Cada syscall, y sus correspondiente wrapper function en C, están descriptas en la sección 2 del manual (man 2 <syscall>).
- La biblioteca estándar de C incluye otras funciones que no son syscalls, pero las utilizan para funcionar. Por ejemplo, printf() invoca a la syscall write(). Estas funciones se detallan en la sección 3 del manual.



Basado en una ilustración de Shmuel Csaba Otto Traian (Wikimedia Commons)





 Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.

- Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.
- Toda señal tiene asociado un número que identifica su tipo. Estos números están definidos como constantes en el header <signal.h>.
 Por ejemplo: SIGINT, SIGKILL, SIGSEGV.

- Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.
- Toda señal tiene asociado un número que identifica su tipo. Estos números están definidos como constantes en el header <signal.h>.
 Por ejemplo: SIGINT, SIGKILL, SIGSEGV.
- Cuando un proceso recibe una señal, su ejecución se interrumpe y se ejecuta un handler.

- Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.
- Toda señal tiene asociado un número que identifica su tipo. Estos números están definidos como constantes en el header <signal.h>.
 Por ejemplo: SIGINT, SIGKILL, SIGSEGV.
- Cuando un proceso recibe una señal, su ejecución se interrumpe y se ejecuta un handler.
- Cada tipo de señal tiene asociado un handler por defecto, que puede ser modificado mediante la syscall signal().

- Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.
- Toda señal tiene asociado un número que identifica su tipo. Estos números están definidos como constantes en el header <signal.h>.
 Por ejemplo: SIGINT, SIGKILL, SIGSEGV.
- Cuando un proceso recibe una señal, su ejecución se interrumpe y se ejecuta un handler.
- Cada tipo de señal tiene asociado un handler por defecto, que puede ser modificado mediante la syscall signal().
- Las señales SIGKILL y SIGSTOP no pueden ser bloqueadas, ni se pueden reemplazar sus *handlers*.

- Las señales son un mecanismo que incorporan los sistemas operativos POSIX, y que permtite notificar a un proceso la ocurrencia de un evento.
- Toda señal tiene asociado un número que identifica su tipo. Estos números están definidos como constantes en el header <signal.h>.
 Por ejemplo: SIGINT, SIGKILL, SIGSEGV.
- Cuando un proceso recibe una señal, su ejecución se interrumpe y se ejecuta un handler.
- Cada tipo de señal tiene asociado un handler por defecto, que puede ser modificado mediante la syscall signal().
- Las señales SIGKILL y SIGSTOP no pueden ser bloqueadas, ni se pueden reemplazar sus handlers.
- Un usuario puede enviar una señal a un proceso con la herramienta kill. Un proceso puede enviar una señal a otro mediante la syscall kill().

Usando strace

strace es una herramienta que nos permite generar una traza legible de las llamadas al sistema usadas por un programa dado.

Usando strace

strace es una herramienta que nos permite generar una traza legible de las llamadas al sistema usadas por un programa dado.

Ejemplo de strace

Usando strace

strace es una herramienta que nos permite generar una traza legible de las llamadas al sistema usadas por un programa dado.

Ejemplo de strace

- execve() convierte el proceso en una instancia nueva de ./tinyhello y devuelve 0 indicando que no hubo error.
- write() escribe en pantalla el mensaje y devuelve la cantidad de caracteres escritos (9).
- exit() termina la ejecución y no devuelve ningún valor.

strace y hello en C

Probemos strace con nuestra versión en C del programa.

```
hello.c
#include <unistd.h>

int main(int argc, char* argv[]) {
  write(1, "Hola SO!\n", 9);
  return 0;
}
```

Vamos a compilar estáticamente:

```
Compilación de hello.c

gcc -static -o hello hello.c
```

strace y hello en C

¿Qué es todo esto?

Las syscalls de hello.c

La que hace "lo que queremos"

```
write(1, "Hola SO!\n", 9) = 9
```

- write() escribe el mensaje "Hola SO!" en la salida indicada.
- En este caso, el valor 1 representa la salida estándar (stdout).
- Devuelve la cantidad de caracteres que se escribieron en la salida.

Las syscalls de hello.c

Llamadas referentes al manejo de memoria

```
brk(0) = 0x831f000

brk(0x831fcb0) = 0x831fcb0

brk(0x8340cb0) = 0x8340cb0

brk(0x8341000) = 0x8341000
```

- brk() y sbrk() modifican el tamaño de la memoria de datos del proceso. malloc() y free() (que no son syscalls) las usan para agrandar o achicar la memoria usada por el proceso.
- Otras comunes suelen ser mmap() y mmap2(), que asignan un archivo o dispositivo a una región de memoria. En el caso de MAP_ANONYMOUS no se mapea ningún archivo; solo se crea una porción de memoria disponible para el programa. Para regiones de memoria grandes, malloc() usa esta syscall.

Las syscalls de hello.c

Otras syscalls

```
execve("./hello", ["./hello"], [/* 17 vars */]) = 0
uname({sys="Linux", node="nombrehost", ...}) = 0
set_thread_area({entry_number:-1 -> 6, base_addr:0x831f830...}) = 0
exit_group(0) = ?
```

- execve() cambia el código del proceso actual por el del programa pasado por parámetro.
- uname() devuelve información del sistema (nombre del host, versión del kernel, etc).
- set_thread_area() registra una porción de memoria como memoria local del (único) thread en la GDT¹ que está corriendo.
- exit_group() termina el proceso (y todos sus threads).



¹Veremos *threads* más adelante.

¿Y compilando dinámicamente?

• Compilemos el mismo fuente hello.c con bibliotecas dinámicas.

¿Y compilando dinámicamente?

- Compilemos el mismo fuente hello.c con bibliotecas dinámicas.
- Si corremos strace sobre este programa, encontramos aún más syscalls:

```
strace de hello.c, compilado dinámicamente
access("/etc/ld.so.nohwcap", F_OK)
                                       = -1 ENOENT (No such file or ...)
mmap2(NULL, 8192, PROT_READ|PROT_WRITE,
     MAP_PRIVATE | MAP_ANONYMOUS, -1, 0) = 0xb8017000
                                       = -1 ENOENT (No such file or ...)
access("/etc/ld.so.preload", R_OK)
open("/etc/ld.so.cache", O_RDONLY)
fstat64(3, {st_mode=S_IFREG|0644, st_size=89953, ...}) = 0
mmap2(NULL, 89953, PROT_READ, MAP_PRIVATE, 3, 0) = 0xb8001000
close(3)
```

 La secuencia open(), fstat(), mmap2() y close() mapea el archivo /etc/ld.so.cache a una dirección de memoria (0xb8001000).

Muchas syscalls para un hello world

Recordemos el código de nuestro programa:

```
hello.c
#include <unistd.h>

int main(int argc, char* argv[]) {
   write(1, "Hola SO!\n", 9);
   return 0;
}
```

- El punto de entrada que usa el *linker* (1d) es _start.
- El punto de entrada de un programa en C es main().
- gcc usa 1d como *linker*, y mantiene su punto de entrada por defecto.
- ¿Qué hay en el medio? ¿Alguna idea?

Muchas syscalls para un hello world

hello.c, compilado dinámicamente y desensamblado

```
Disassembly of section .text:
08048130 <_start>:
 8048130:
          31 ed
                                 ebp,ebp
                          xor
8048132: 5e
                                 esi
                          pop
8048133: 89 e1
                          mov
                                 ecx,esp
8048135: 83 e4 f0
                          and
                                 esp,0xffffff0
8048138: 50
                          push
                                 eax
8048139: 54
                          push
                                esp
804813a: 52
                          push
                               edx
804813b: 68 70 88 04 08
                          push
                               0x8048870
          68 b0 88 04 08
8048140:
                          push
                               0x80488b0
8048145:
          51
                          push
                               ecx
8048146:
          56
                          push
                               esi
8048147: 68 f0 81 04 08
                          push
                               0x80481f0
804814c: e8 cf 00 00 00
                          call 8048220 <__libc_start_main>
8048151:
          f4
                          hlt.
```

¡La **libc**!

Muchas syscalls para un hello world

Código de la **libc**:

```
libc: función __libc_start_main()
STATIC int LIBC_START_MAIN (
   int (*main) (int, char **, char ** MAIN_AUXVEC_DECL),
   int argc, char *_unbounded *_unbounded ubp_av,
#ifdef LIBC_START_MAIN_AUXVEC_ARG
   ElfW(auxv_t) *_unbounded auxvec,
#endif
   __typeof (main) init,
   void (*fini) (void),
   void (*rtld_fini) (void), void *_unbounded stack_end)
{
   /* Nothing fancy, just call the function. */
 result = main (argc, argv, __environ MAIN_AUXVEC_PARAM);
 exit (result);
```

Más sobre strace

Demo en vivo. Algunos ejemplos "de la vida real":

- date
- cat
- time date

Más sobre strace

Demo en vivo. Algunos ejemplos "de la vida real":

- date
- cat
- time date

Algunas opciones útiles:

- -q: Omite algunos mensajes innecesarios.
- -o <archivo>: Redirige la salida a <archivo>.
- -f: Traza también a los procesos hijos del proceso trazado.

Más sobre strace

Demo en vivo. Algunos ejemplos "de la vida real":

- date
- cat
- time date

Algunas opciones útiles:

- -q: Omite algunos mensajes innecesarios.
- -o <archivo>: Redirige la salida a <archivo>.
- -f: Traza también a los procesos hijos del proceso trazado.

Como siempre, más detalles en man strace. (¿Todavía hace falta?).

¿Y strace cómo funciona?

¿Y strace cómo funciona? strace strace.

¿Y strace cómo funciona? strace strace.

El secreto es la syscall ptrace().

¿Y strace cómo funciona? strace strace.

El secreto es la syscall ptrace(). Veamos qué tiene para decir el manual.

man 2 ptrace

```
NOMBRE.
```

ptrace - rastreo de un proceso

SINOPSIS

#include <sys/ptrace.h>

DESCRIPCIÓN

La llamada al sistema ptrace proporciona un medio por el que un proceso padre puede observar y controlar la ejecución de un proceso hijo y examinar y cambiar su imagen de memoria y registros. Se usa principalmente en la implementación de depuración con puntos de ruptura y en el rastreo de llamadas al sistema.

Vamos a usar ptrace() para monitorear un proceso.

Prototipo de ptrace()

request puede ser alguno de estos:

- PTRACE_TRACEME, PTRACE_ATTACH, PTRACE_DETACH,
- PTRACE_KILL, PTRACE_CONT,
- PTRACE_SYSCALL, PTRACE_SINGLESTEP,
- PTRACE_PEEKDATA, PTRACE_POKEDATA,
- PTRACE_PEEKUSER, PTRACE_POKEUSER,
- ...y más².

²Ver man 2 ptrace.

Situación:

- Proceso padre.
- Proceso hijo que queremos monitorear.

Inicialización. Dos alternativas:

- 1 El proceso hijo solicita ser monitoreado por su padre haciendo una llamada a ptrace(PTRACE_TRACEME). Por ejemplo, después de un fork() y antes de un execve().
- 2 El proceso padre se engancha al proceso hijo con la llamada ptrace(PTRACE_ATTACH, pid_child). Esto permite engancharse a un proceso que ya está corriendo (si se tienen permisos suficientes).

Finalización:

 Con la llamada ptrace(PTRACE_DETACH, pid_child) se deja de monitorear.

ptrace() permite monitorear tres tipos de eventos:

- 1 Señales: cuando el proceso hijo recibe una señal.
- 2 Syscalls: cada vez que el proceso hijo entra o sale de la llamada a una syscall.
- 3 Instrucciones: cuando el proceso hijo ejecuta una instrucción.

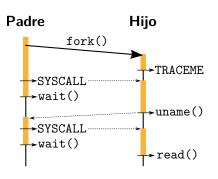
ptrace() permite monitorear tres tipos de eventos:

- 1 Señales: cuando el proceso hijo recibe una señal.
- 2 Syscalls: cada vez que el proceso hijo entra o sale de la llamada a una syscall.
- 3 Instrucciones: cuando el proceso hijo ejecuta una instrucción.

Cada vez que se genera un **evento**, el proceso hijo se detiene. El padre se entera mediante una llamada (bloqueante) a la *syscall* wait(), que retorna al producirse el evento. Luego, puede **reanudar** al hijo hasta:

- la siguiente señal recibida, llamando a ptrace(PTRACE_CONT).
- 2 la siguiente señal recibida o syscall ejecutada, llamando a ptrace(PTRACE_SYSCALL).
- 3 solo por una instrucción, llamando a ptrace(PTRACE_SINGLESTEP).

ptrace(): Esquema de uso (simplificado)

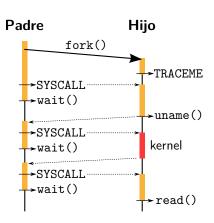


Ejemplo **simplificado** del mecanismo de bloqueo de ptrace().

El hijo se detiene cada vez que llama a una syscall.

El padre lo reanuda con una llamada a ptrace(PTRACE_SYSCALL).

ptrace(): Esquema de uso



En realidad, el padre recibe **dos** eventos, al entrar y salir de la *syscall*.

ptrace(): Esquema de comunicación

- Se inicializa el mecanismo de ptrace() (PTRACE_TRACEME o PTRACE_ATTACH).
- 2 padre: Llama a wait(); espera el próximo evento del hijo.
- **3 hijo**: Ejecuta normalmente hasta que se genere un evento (recibir una señal, hacer una syscall o ejecutar una instrucción).
- 4 hijo: Se genera el evento y el proceso se detiene.
- 6 padre: Vuelve de la syscall wait().
- **6 padre**: Puede inspecionar y modificar el estado del hijo: registros, memoria, etc.
- padre:
 - Reanuda el proceso hijo con PTRACE_CONT, PTRACE_SYSCALL o PTRACE_SINGLESTEP y vuelve a 2,
 - o bien termina el proceso con PTRACE_KILL o lo libera con PTRACE_DETACH.

Ejemplo: launch

A modo de ejemplo, consideremos un programa, launch.c, que permite poner a ejecutar otro programa.

```
launch.c - main()
/* Fork en dos procesos */
child = fork():
if (child == -1) { perror("ERROR fork"); return 1; }
if (child == 0) {
 /* Solo se ejecuta en el hijo */
 execvp(argv[1], argv + 1);
 /* Si vuelve de exec() hubo un error */
 perror("ERROR child exec(...)"); exit(1);
} else {
 /* Solo se ejecuta en el padre */
 while(1) {
    if (wait(&status) < 0) { perror("wait"); break; }</pre>
   if (WIFEXITED(status)) break; /* Proceso terminado */
```

Eiemplo: launch + ptrace()

launch.c + ptrace

```
/* Fork en dos procesos */
child = fork():
if (child == -1) { perror("ERROR fork"); return 1; }
if (child == 0) {
  /* Solo se ejecuta en el hijo */
  if (ptrace(PTRACE_TRACEME, 0, NULL, NULL)) {
    perror("ERROR child ptrace(PTRACE_TRACEME, ...)"); exit(1);
  execvp(argv[1], argv + 1);
  /* Si vuelve de exec() hubo un error */
  perror("ERROR child exec(...)"); exit(1);
} else {
  /* Solo se ejecuta en el padre */
  while(1) {
    if (wait(&status) < 0) { perror("wait"); break; }</pre>
    if (WIFEXITED(status)) break; /* Proceso terminado */
    ptrace(PTRACE_SYSCALL, child, NULL, NULL); /* Continúa */
  ptrace(PTRACE_DETACH, child, NULL, NULL); /* Liberamos al hijo */
```

28 de marzo de 2017

ptrace(): Modificando el estado del proceso hijo

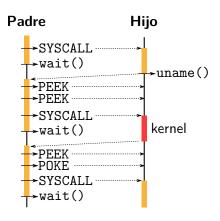
ptrace() permite acceder a la memoria del proceso hijo.

- PTRACE_PEEKDATA y PTRACE_POKEDATA: leer (PEEK) o escribir (POKE) cualquier dirección de memoria en el proceso hijo.
- PTRACE_PEEKUSER, PTRACE_POKEUSER: leer o escribir la memoria de usuario que el sistema guarda al iniciar la syscall (registros y estado del proceso).

Ejemplos

- Obtener el número de syscall llamada: int sysno = ptrace(PTRACE_PEEKUSER, child, 4 * ORIG_EAX, NULL);
- Leer la dirección addr (memoria del proceso hijo): unsigned int valor = ptrace(PTRACE_PEEKDATA, child, addr, NULL);
- Escribir otro valor en la direccion addr: ptrace(PTRACE_POKEDATA, child, addr, valor + 1);

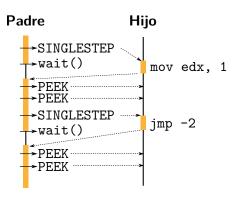
ptrace(): Esquema de uso - Obteniendo datos



Mientras el proceso hijo está detenido, se pueden obtener y modificar datos con

- PTRACE_PEEKDATA,
- PTRACE_POKEDATA,
- PTRACE_PEEKUSER y
- PTRACE_POKEUSER.

ptrace(): Esquema de uso - Debugger



Un debugger puede usar PTRACE_SINGLESTEP para ejecutar paso a paso cada instrucción.